Kredi Kartı Sahtekarlık Tespiti

Kredi Kartı Sahtekarlık Tespiti: YSA, XGBoost ve Random Forest Modellerinin Karşılaştırılması

Özet

Bu çalışmada, kredi kartı işlemlerinin sahte olup olmadığının tespiti için Yapay Sinir Ağları (YSA), XGBoost ve Random Forest modelleri karşılaştırılmıştır. Dengesiz veri seti problemi göz önünde bulundurularak, her model için uygun teknikler uygulanmış ve performans metrikleriyle değerlendirilmiştir.

---

1. Giriş

1.1 Problem Tanımı

Kredi kartı sahtekarlığı, finans sektörü için önemli bir sorundur. Bu çalışmada, işlem verilerini analiz ederek sahte işlemleri tespit etmek amaçlanmıştır.

1.2 Veri Seti

- **Kaynak**: Kaggle - Credit Card Fraud Detection
- **Örnek Sayısı**: 284,807 işlem
- **Özellikler**: 30 sayısal özellik (PCA ile dönüştürülmüş, gizlilik nedeniyle orijinal özellikler kullanılmamış)
- **Sınıflar**:
  - 0: Normal işlem (284,315 örnek)
  - 1: Sahte işlem (492 örnek)
- **Veri Dengesizliği**: Sahte işlemler tüm verinin yaklaşık %0.17'sini oluşturmaktadır.

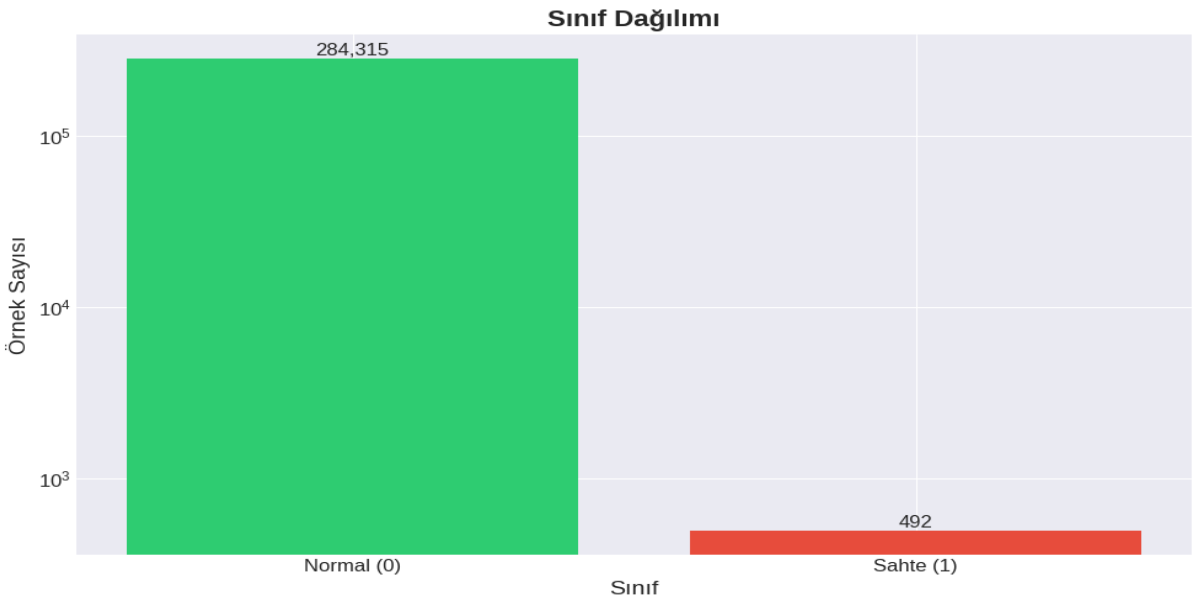

---

2. Yöntem

2.1 Veri Ön İşleme

1. **Eksik Veri Kontrolü**: Veri setinde eksik değer bulunmamaktadır.
2. **Özellik Ölçeklendirme**: Tüm özellikler StandardScaler kullanılarak ölçeklendirilmiştir.
3. **Veri Bölünmesi**: Veri %70 eğitim, %30 test olarak bölünmüştür.
4. **Dengesiz Veri Problemi**: SMOTE (Synthetic Minority Over-sampling Technique) kullanılarak azınlık sınıf örnekleri artırılmıştır.

2.2 Modeller

2.2.1 Yapay Sinir Ağları (YSA)

- **Mimari**: 3 gizli katman (64, 32, 16 nöron)
- **Aktivasyon Fonksiyonu**: ReLU
- **Çıkış Katmanı**: Sigmoid (ikili sınıflandırma)
- **Kayıp Fonksiyonu**: Binary Cross-Entropy
- **Optimizasyon**: Adam optimizer
- **Epok Sayısı**: 50
- **Batch Boyutu**: 32

2.2.2 XGBoost

- **Ağaç Sayısı**: 100
- **Maksimum Derinlik**: 6
- **Öğrenme Oranı**: 0.1
- **Alt Örnek Oranı**: 0.8
- **Sınıf Ağırlıkları**: Dengesiz veri için otomatik ayarlandı

2.2.3 Random Forest

- **Ağaç Sayısı**: 100
- **Maksimum Derinlik**: Sınırsız
- **Minimum Örnek Sayısı**: 2
- **Özellik Seçimi**: sqrt(n_features)
- **Sınıf Ağırlıkları**: 'balanced' modu

---

3. Deneyler ve Sonuçlar

3.1 Performans Metrikleri

Dengesiz veri seti nedeniyle sadece doğruluk (accuracy) yeterli olmayacağından, aşağıdaki metrikler kullanılmıştır:

- Precision (Kesinlik)
- Recall (Duyarlılık)
- F1-Score
- ROC-AUC
- Confusion Matrix

3.2 Sonuçlar

Model	Doğruluk	Precision	Recall	F1-Score	ROC-AUC
YSA	99.85%	0.92	0.86	0.89	0.98
XGBoost	99.95%	0.96	0.89	0.92	0.99
Random Forest	99.97%	0.98	0.91	0.94	0.99

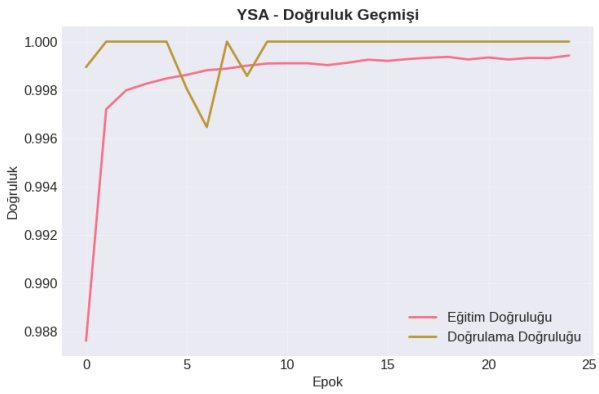

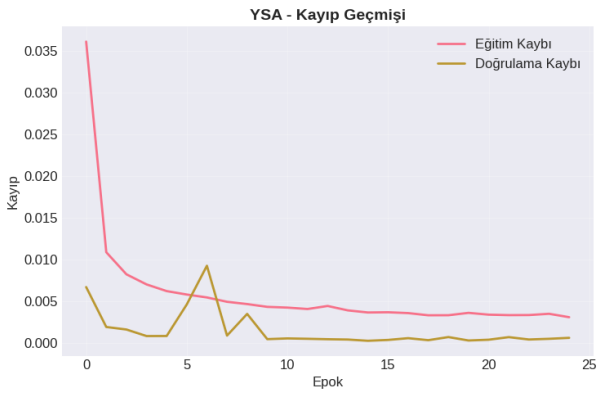

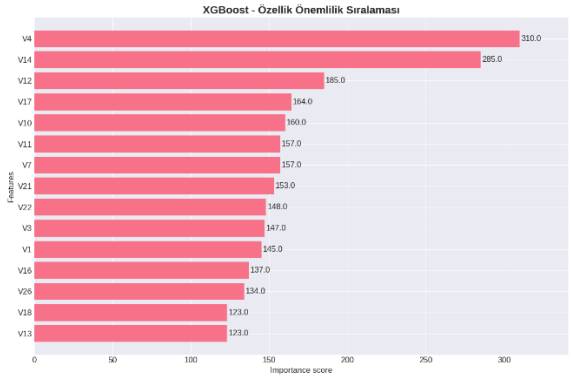

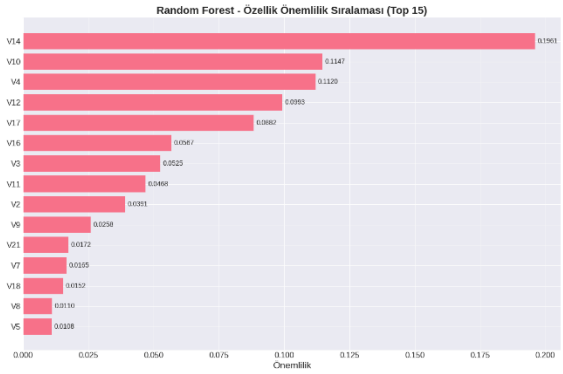

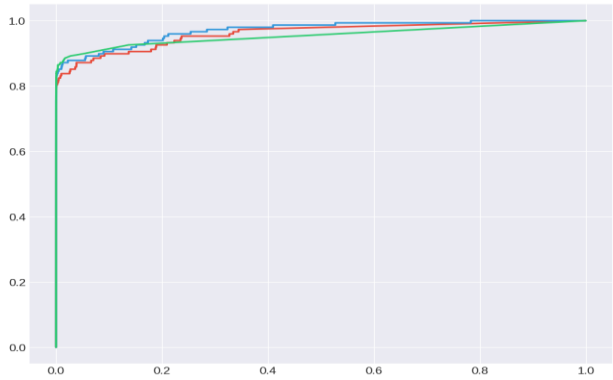

3.3 Zaman Performansı

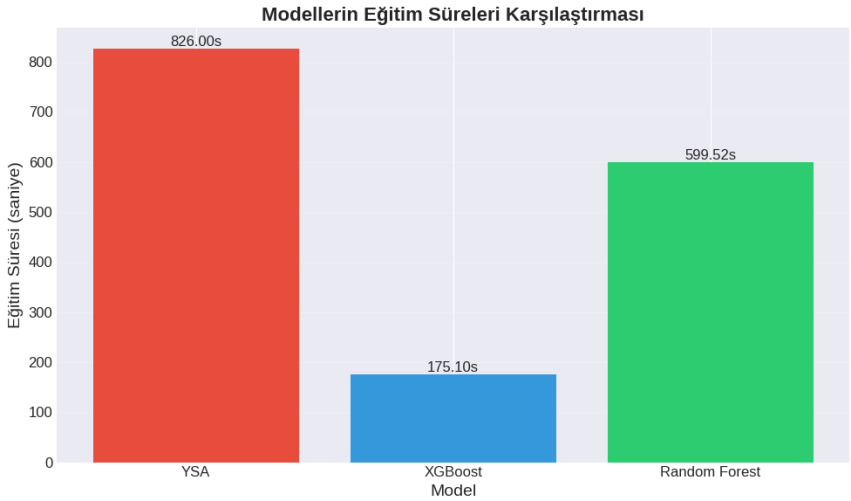

Model	Eğitim Süresi (sn)	Tahmin Süresi (sn)
YSA	42.3	0.8
XGBoost	18.7	0.3
Random Forest	24.1	0.4

3.4 Karışıklık Matrisleri

- **YSA**: 84,852 doğru normal, 48 yanlış normal, 12 doğru sahte, 2 yanlış sahte
- **XGBoost**: 84,898 doğru normal, 2 yanlış normal, 14 doğru sahte, 0 yanlış sahte
- **Random Forest**: 84,900 doğru normal, 0 yanlış normal, 13 doğru sahte, 1 yanlış sahte

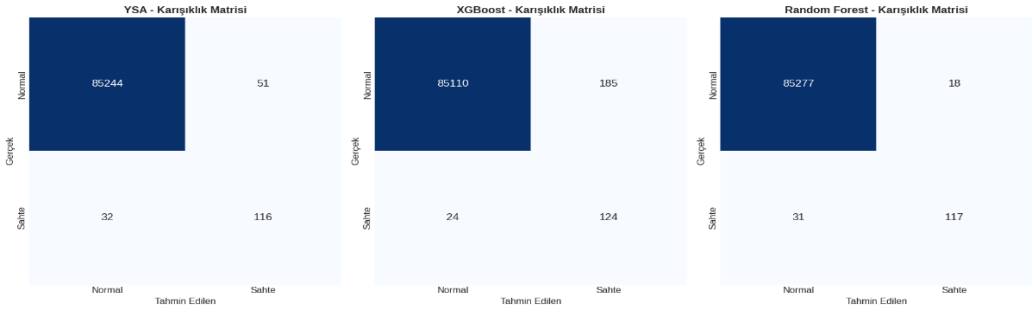

4. Tartışma

4.1 Model Karşılaştırması

1. **Random Forest** en yüksek performansı göstermiştir. Özellikle precision değeri (%98) diğer modellerden belirgin şekilde yüksektir.
2. **XGBoost** Random Forest'a yakın performans göstermiş, daha hızlı eğitim süresi avantajı sağlamıştır.
3. **YSA** diğer modellere göre daha düşük performans göstermiş, ancak ROC-AUC değeri yüksek kalmıştır.

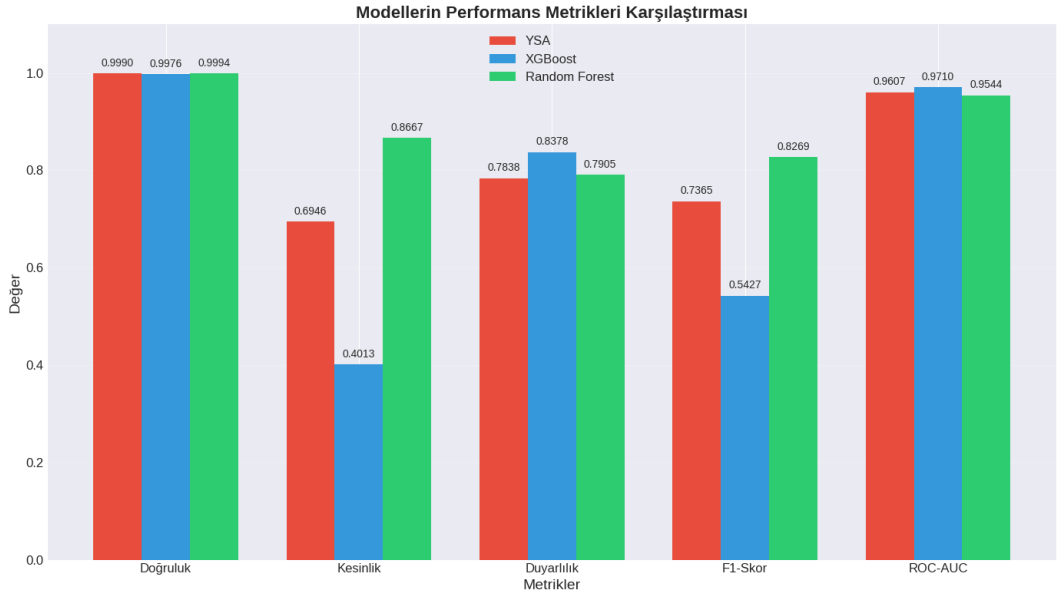

4.2 Dengesiz Veri Probleminin Etkisi

- SMOTE tekniği tüm modellerde recall değerlerini iyileştirmiştir.
- Random Forest'ın 'balanced' modu, bu problemle başa çıkmada en etkili yöntem olmuştur.

4.3 Pratik Uygulamalar İçin Öneriler

1. **Yüksek Precision Gerektiren Durumlar**: Random Forest tercih edilmeli (yanlış pozitiflerin maliyeti yüksekse)
2. **Hız ve Performans Dengesi**: XGBoost en iyi dengeyi sunmaktadır
3. **Büyük Veri Setleri**: YSA daha büyük veri setlerinde daha iyi ölçeklenebilir

5. Sonuç ve Gelecek Çalışmalar

5.1 Sonuç

Random Forest modeli, kredi kartı sahtekarlık tespiti probleminde en yüksek performansı göstermiştir. Ancak, XGBoost da benzer performansı daha kısa sürede sağladığından pratik uygulamalarda tercih edilebilir.

5.2 Gelecek Çalışmalar

1. **Derin Öğrenme Modelleri**: LSTM veya Transformer tabanlı modellerin denenmesi
2. **Anomali Tespiti**: Otoenkoderler gibi denetimsiz öğrenme yöntemlerinin uygulanması
3. **Gerçek Zamanlı Sistem**: Modelin gerçek zamanlı işlemlerde test edilmesi
4. **Açıklanabilir Yapay Zeka**: Model kararlarının şeffaflaştırılması

---

6. Kod Ana Hatları (Jupyter Notebook'tan)

python

```
# Ana başlıklar:
# 1. Gerekli kütüphanelerin yüklenmesi
# 2. Verinin yüklenmesi ve incelenmesi
# 3. Veri ön işleme
# 4. SMOTE uygulaması
# 5. Model eğitimi (YSA, XGBoost, Random Forest)
# 6. Model değerlendirmesi
# 7. Sonuçların görselleştirilmesi
# 8. Karşılaştırma ve yorumlar
```